

20 - Prática: Reconhecimento de Emoções com TensorFlow 2.0 e Python (III)

Eduardo Prasniewski

1 Seção 1

Introdução ao curso.

2 Seção 2

Primeiramente define as aplicações do reconhecimento de emoções, pontuando a área da computação afetiva. Depois apresenta um mini projeto para detectar expressões faciais utilizando opencv, com modelos pré-treinados de Haar Cascade que detectam as expressões. Com o modelo é possível determinar um ponto e a partir deste ponto recortar uma região de interesse da imagem (ROI), que será utilizada posteriormente.

Link Colab: Colab - ROI

3 Seção 3

Apresenta uma introdução da rede neural e seus conceitos como: filtros, max pooling, flattening etc. Posteriormente da início a construção da arquitetura, fazendo: extração de dados a partir de um zip (pertencente a uma competição do Kaggle) que serve como base de imagens, extração das características disponibilizadas via arquivo CSV para uso.

Define a arquitetura da CNN, indo de passo a passo a criação da mesma, de modo sequencial, explicando conceitos de padding, dropout, maxpooling e batches. Introduz também conceitos como EarlyStopper, ReduceLROnPlateau e Checkpointer.

Após o treinamento da rede neural, que teve seu earlystopper localizado na epoca aproximadamente 35, gráficos referentes a acurácia e erros do treinamento foram realizados e apresentados com uma matriz de confusão.

Posteriormente, o modelo utilizado e treinado é usado com vídeo, detectando assim as emoções frame a frame (esta parte da seção eu não coloquei em prática visto que era apenas uma extensão do uso com imagens.).

Link Colab: : Colab - CNN

4 Seção 4

Trata-se de uma seção explicativa de como funciona de forma ilustrativa e brevemente matemática como funcionam as redes neurais tradicionais, mais especificamente os perceptrons.

Primeiramente comenta sobre problemas com soluções lineares e problemas não-lineares, sendo o último mais utilizado no contexto de aprendizagem de máquina. Apresenta as camadas de entradas, escondidas e saída; os cálculos de erro (erro absoluta, MSE e RMSE); variações da descida do gradiente (como o Stochastic Gradient Descent, ou SGD, muito utilizado nas aplicações para encontrar o mínimo global e não local da função); conceitos do backpropagation, que visa ajustar os pesos da rede neural para que atinja o objetivo; e o bias, um nodo a mais

em cada camada que força o valor a não zerar em casos que seria zerados os valores para a próxima camada.

Por fim, o professor realiza a implementação de algumas funções de ativação e explica a funcionalidade de cada uma.

5 Seção 5

Seção extra.